



网页多模态 Agent 开题报告

基于多模态大模型的网页智能 Agent 设计与实现

小组成员 _____ 陈曾嵘 (23336031)

_____ 郑皓 (23336328)

_____ 林华杰 (23336136)

院 系 _____ 计算机学院

专 业 _____ 计算机科学与技术

指导教师 _____ 刘阳老师

_____ 2026 年 5 月

目录

1	引言	2
2	项目背景与意义	2
3	系统设计方案	3
4	核心实现思路	5
4.1	网页自动化控制	5
4.2	多模态网页理解	6
4.3	Agent 动作决策	6
5	项目实施计划	6
6	预期成果	7
7	总结与展望	7

1 引言

随着大语言模型（LLM）与多模态视觉模型（VLM）的快速发展，智能 Agent 逐渐从传统文本交互扩展到具备网页理解与自动操作能力的新阶段。网页 Agent 能够通过观察网页界面、理解用户目标，并自动执行点击、输入、搜索等操作，在智能办公、自动测试、信息检索等领域具有广泛应用前景。

本项目拟设计并实现一个基于多模态大模型的网页智能 Agent 系统，实现“自然语言任务输入—网页理解—动作规划—自动执行”的完整闭环。系统将结合浏览器自动化工具与视觉语言模型，使 Agent 能够感知网页环境并完成基本网页任务。

本项目的研究目标包括：

- 实现网页自动化控制与页面信息获取；
- 实现网页元素识别与页面理解；
- 构建 Agent 动作规划与执行框架；
- 完成典型网页任务的自动执行 Demo。

2 项目背景与意义

当前主流大模型已经具备较强的自然语言推理能力，但在真实互联网环境中的自主交互能力仍然有限。传统网页自动化通常依赖固定脚本，缺乏灵活性，无法适应动态网页结构变化。

相比传统规则系统，多模态网页 Agent 具有以下优势：

- 能够理解复杂网页界面；
- 可以根据自然语言动态规划任务；
- 具备一定的泛化能力与自主决策能力；
- 更符合未来智能助手的发展方向。

因此，研究网页多模态 Agent 对于理解 AI Agent 系统设计、网页自动化技术以及多模态融合方法具有重要意义。

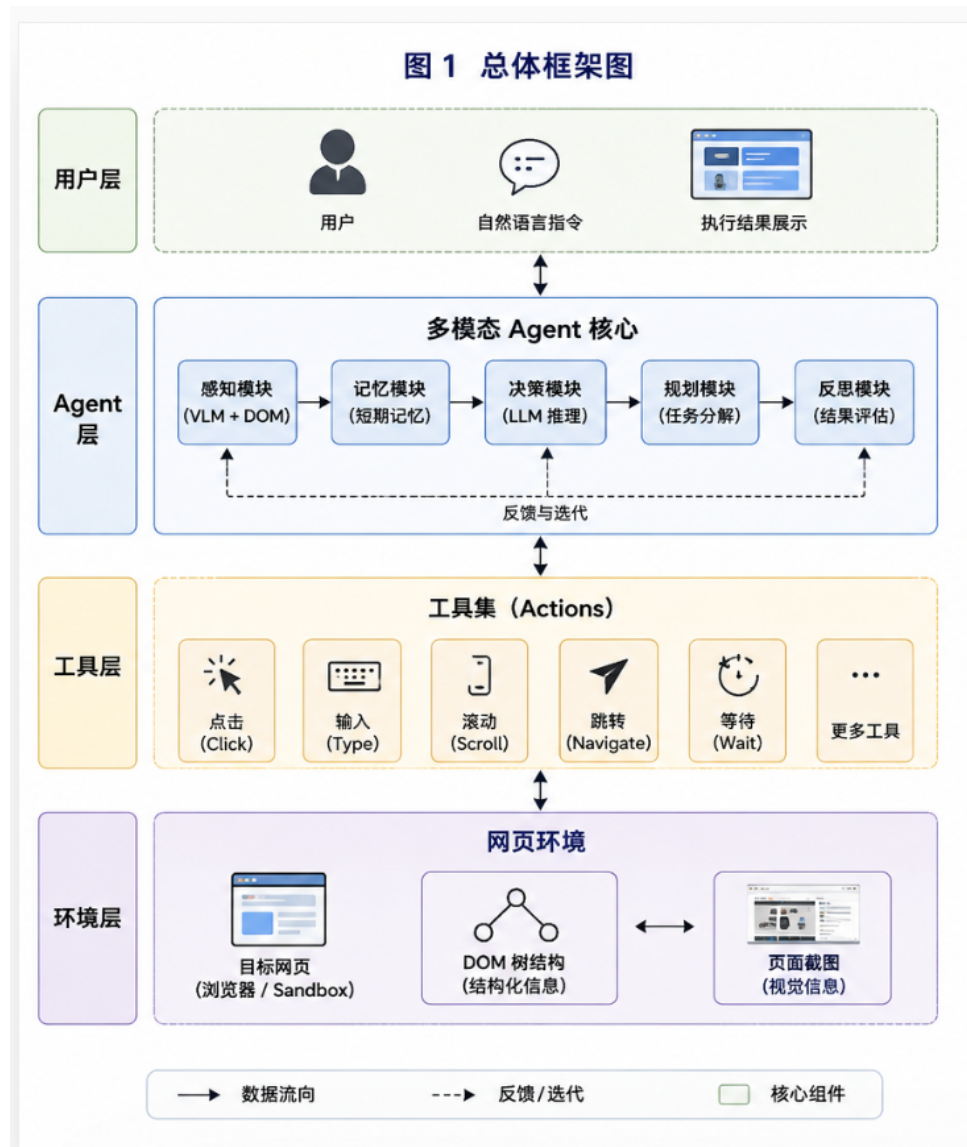


图 1: 网页多模态 Agent 总体框架

3 系统设计方案

本项目采用“网页感知 + Agent 规划 + 浏览器执行”的整体架构，系统主要由以下几个模块组成：

1. 页面感知模块
2. 多模态理解模块
3. Agent 决策模块
4. 浏览器执行模块
5. 日志与结果反馈模块

系统整体流程如下：

用户输入任务 → 网页截图与 DOM 提取 → 多模态模型分析 → Agent 生成动作 → 浏览器执行

本项目计划采用如下技术方案：

表 1: 项目技术栈

模块	技术方案
大语言模型	Qwen2.5 / DeepSeek
多模态模型	Qwen2.5-VL
浏览器自动化	Playwright
开发语言	Python
前端展示	Gradio

其中，Playwright 用于网页自动操作，包括点击、输入、滚动和截图；多模态模型用于理解网页截图内容；LLM 用于生成下一步动作决策。

图 2 Agent 执行流程图




图 2: Agent 执行流程图

4 核心实现思路

项目实现将重点围绕以下三个方面展开：

4.1 网页自动化控制

使用 Playwright 实现浏览器控制，包括：

- 自动打开网页

- 自动输入与点击
- 页面截图获取
- 网页元素定位

4.2 多模态网页理解

系统将结合 DOM 结构与网页截图实现混合感知：

- DOM 用于精确定位页面元素；
- 截图用于整体页面语义理解；
- VLM 用于识别按钮、输入框等关键区域。

4.3 Agent 动作决策

系统通过 Prompt 驱动 LLM 进行动作规划，例如：

“当前页面有哪些元素？下一步应该执行什么操作？”

Agent 将根据用户目标不断循环执行：

观察页面 → 生成动作 → 执行动作 → 更新状态

5 项目实施计划

本项目计划分阶段完成，预计周期约两周。

表 2: 项目时间安排

时间	工作内容
第 1-2 天	环境搭建与 Playwright 测试
第 3-4 天	网页 DOM 解析实现
第 5-6 天	Agent 动作规划模块开发
第 7-8 天	基础任务闭环实现
第 9-10 天	接入多模态模型
第 11-12 天	系统测试与实验分析
第 13-14 天	报告与演示整理

项目最终将完成至少以下典型任务：

- 百度搜索任务
- B 站内容搜索
- 电商商品检索

微调 & 评测 初步计划是使用 Mind2Web（偏 DOM）和 MiniWoB++（偏视觉）数据集，二者结合用于大模型微调，同时考虑自行补充信息以对这两个数据集进行扩展。评测指标使用 WebArena，同时对动作稳定性和失败原因等进行统计分析。

算力预算 中大超算 / 阿里云 / 一到两张 RTX 3090

6 预期成果

本项目预期完成以下成果：

- 一个具备网页自动操作能力的多模态 Agent 系统；
- 支持自然语言输入与自动网页交互；
- 支持页面截图理解与元素识别；
- 完成多个真实网页任务 Demo；
- 输出实验结果与性能分析报告。

最终系统将具备一定自主决策能力，并能够完成简单互联网任务，为后续智能 Agent 研究提供实践基础。

7 总结与展望

本项目围绕“网页多模态 Agent”展开研究，重点探索多模态感知、网页自动化与 Agent 动作规划之间的结合方式。项目不仅能够帮助团队深入理解大模型 Agent 系统的实现原理，也能够提高对网页自动化与多模态交互技术的实践能力。

未来可进一步扩展以下方向：

- 增强复杂网页环境适应能力；
- 引入长期记忆与自反思机制；
- 支持更加复杂的互联网任务；
- 提高多模态理解准确率与稳定性。

参考文献

- [1] Microsoft Research. VisualWebArena: Evaluating Multimodal Web Agents, 2024.
- [2] Playwright Official Documentation.
- [3] <https://arxiv.org/abs/2306.06070> (Mind2Web 数据集)
- [4] <https://arxiv.org/abs/2307.13854> (WebArena 评测指标)
- [5] <https://github.com/Farama-Foundation/miniwob-plusplus> (MiniWob++ 数据集)